

视频生成领域的新范式探索：基于大型语言模型的物理对齐、智能体规划与连续表征研究

引言：超越感知指标的范式转移

在视频生成领域的历史发展轨迹中，研究界长期受制于对感知保真度的无尽追求。传统的演进路线高度依赖于诸如弗雷歇视频距离(FVD)、初始分数(IS)以及CLIP相似度等量化指标的提升。在2023年至2024年的扩散模型时代，学术界的焦点几乎完全锚定于文本到视频的语义对齐、高分辨率合成以及帧间的时间平滑度¹。然而，随着Sora、Wan以及Kling等基础大模型展现出近乎照片级真实的生成能力，单纯依赖像素级感知指标进行模型优化的边际效用正在急剧递减¹。在此背景下，研究前沿正在发生根本性的范式转移，开始向那些长期被忽视的维度进军：物理规律的内在对齐、无限上下文的视频理解、智能体驱动的场景编排、显式的世界模型构建，以及人机交互的深度融合¹。

这种底层逻辑的转变反映了一个广泛的共识：文本到视频(Text-to-Video, T2V)生成正在从单纯的“图像动画化”任务，演变为构建具有物理基础的“世界模拟器”¹。研究人员越来越多地发现现代生成模型中存在的系统性缺陷，例如缺乏因果推理能力、在面对反直觉物理规律时容易产生严重的幻觉，以及在长周期生成中出现灾难性的时空遗忘⁷。为了解决这些本质问题，大型语言模型(LLM)和视觉语言模型(VLM)正在被重新定义。LLM不再仅仅被视为将提示词映射到隐空间的文本编码器，而是被部署为认知导演、场景规划师、物理模拟器和交互式智能体²。本报告旨在详尽剖析视频生成领域中这些新兴的子任务，刻意避开传统的“指标刷榜”竞赛，转而聚焦于新问题的发掘、结构性缺陷的修复，以及智能体与连续表征新范式的开拓，为不以提升常规指标为目的的LLM视频生成研究提供深度的理论支撑与方向指引。

跨越离散与连续的鸿沟：视频数据表征的新纪元

自回归视觉生成模型的一个基础性瓶颈在于数据表征机制本身。历史上，该领域在离散分词(Discrete Tokenization)与连续向量表征(Continuous Representation)之间存在着深刻的分歧。离散词元通常通过向量量化变分自编码器(VQ-VAE)提取，这种方式使得视觉模型能够直接复用标准交叉熵损失进行建模，完美映射了基于文本的LLM的成功经验¹¹。然而，量化过程不可避免地会导致严重的信息丢失、受限的词表约束以及分词器训练的不稳定性，这极大地降低了模型在合成复杂时空动态时的表现力¹¹。相反，连续词元虽然能够保留高保真的视觉细节，但需要极其复杂甚至难以收敛的分布建模框架，这显著增加了生成流水线的工程复杂度¹¹。

2024至2025年的最新范式试图弥合这一分歧或彻底绕过它。TokenBridge架构完美诠释了这种过渡，它引入了一种全新的方法论，在保留连续向量强大表征能力的同时，维持了离散词元在建模上的极简性¹¹。这一突破是通过将离散化阶段与分词器训练过程解耦来实现的，具体采用了训练后量化(Post-training Quantization)技术¹¹。通过采用逐维度量化策略(Dimension-wise Quantization)对每个特征维度进行独立离散化，并辅以轻量级的自回归预测机制，系统能够极其高效地对庞大的词元空间进行建模¹¹。这种创新使得模型在不放弃标准分类预测的前提下，达到了与纯连续方法相媲美的重建与生成质量¹¹。

与此同时，另一部分研究者主张彻底摒弃离散词元，全面转向连续公式。连续自回归语言模型(CALM)框架引发了一场从离散的“下一个词元预测”到连续的“下一个向量预测”的激进转变¹³。认识到LLM的效率从根本上受限于逐词元的串行生成过程，CALM利用高保真自编码器将包含 K 个词元的块(Chunk)压缩为单一连续向量¹³。这些压缩的连续表征随后能够以超过99.9%的准确率被解码，使得模型能够将语言及多模态数据视为连续向量序列，从而将生成步骤大幅减少了 K 倍¹³。这一范式需要一种全新的无似然(Likelihood-free)框架来确保连续域中的鲁棒训练和可控采样，从根本上改变了性能与计算资源之间的权衡曲线¹³。

在时空建模的微观层面，诸如CogVideoX等开源基础大模型采用了基于扩散公式训练的连续3D因果卷积分词器¹⁴。这些较新的连续架构摒弃了前辈模型(如W.A.L.T.)中广泛使用的交错式空间与时间窗口注意力机制，转而采用跨越所有时空词元的全局全注意力(Full-attention)机制¹⁴。推动这一架构转向的核心观察在于，分离的空间与时间注意力在处理帧与帧之间的大幅度运动位移时存在固有的缺陷，这深刻地揭示了底层数据表征模式的改变如何直接决定最终视频输出的物理连贯性¹⁴。

表征范式	核心机制	核心优势	局限性与挑战
离散分词 (Discrete)	VQ-VAE量化，交叉熵损失优化。	自回归建模简单，训练动态稳定，易与传统LLM集成。	存在信息瓶颈，视觉细节退化，动作流畅度受限于词表大小。
连续向量 (Continuous)	高保真自编码(如CALM)，向量场学习，全注意力机制。	完美保留微观细节，通过块压缩大幅减少生成步数。	需无似然框架支持，连续分布的建模难度极高。
混合桥接 (Hybrid)	训练后量化，逐维度独立离散化(TokenBridge)。	兼具连续表征的高保真度与离散预测的建模极简性。	在量化层引入了额外的架构复杂性与解耦成本。

无限视频理解与长周期时空记忆的前沿探索

尽管当代多模态大型语言模型(MLLMs)在处理短视频片段时表现优异，但其上下文窗口的计算边界严重制约了它们在长时空跨度上的推理能力。传统的注意力架构在长达数分钟甚至数小时的视频中，难以维持时间连贯性、追踪复杂的事件序列以及保留细粒度的线索⁵。因此，学术界正在向“无限视频理解”(Infinite Video Understanding)迈进——这一蓝天研究目标旨在赋予模型持续处

理、理解并推理任意长度甚至永不中断的视频流的能力⁵。

追求无限上下文必须打破标准自注意力机制中计算量随序列长度呈平方级增长的算力瓶颈。传统的受限上下文窗口（通常上限为128K至1M个词元）与以标准帧率（例如24 FPS）运行的连续视频流所产生的庞大视觉词元密度之间存在着不可调和的矛盾¹⁶。为规避这一问题，学术界正在开发流式架构和持久记忆机制，将短期观察抽象为低维的长期记忆（Long-term Memory, LTM）¹⁵。例如，StreamingVLM系统引入了一种极其紧凑的键值（Key-Value, KV）缓存设计，专为在严格GPU显存预算下实现近乎无限的视频理解而打造¹⁷。通过持久化复用注意力汇（Attention-sink）状态，并结合经过高度优化的近期视觉词元短窗口与近期刊本文词元长窗口，该模型在不使局部内存过载的情况下，完美维持了历史上下文¹⁷。为了在不使模型在优化期间暴露于计算成本极其高昂的超长序列的情况下训练这种流式模式，研究人员采用了重叠块的全注意力监督微调（SFT）策略，这为超长视频的持续摄取开辟了新路径¹⁷。

无限视频推理同样要求在位置编码方面进行根本性创新。扩展视频序列中错综复杂的时空结构会导致传统旋转位置编码出现灾难性的语义退化。诸如HoPE和VideoRoPE++等方法引入了混合频率分配策略与动态时间缩放机制，以促进极其稳健的长度泛化能力⁵。通过根据流式上下文长度动态调整频率，这些位置编码系统能够跨越数以百万计的交错视觉词元，精准保留事件的时间拓扑完整性⁵。

另一个并行的发展方向是视频表征的层次化重构。诸如VideoTree等框架将密集的视频上下文压缩为自适应的树状结构表征，允许LLM通过修剪无关帧并汇总语义分支来对长视频进行高效推理¹⁵。类似地，Video-XL等模型实施了特定于视频的数据集修剪策略以及查询感知选择器（Query-aware Selector），使得轻量级架构能够在成千上万帧的画面中精确定位与查询强相关的词元，彻底绕过冗余的时间数据¹⁵。向无限理解的转变正在催生自适应内存调度、分层词元修剪和流式推理等领域的深刻创新，将视频处理从传统的批处理任务重新定义为一种不间断的语义连续体解析过程⁵。

智能体规划与大语言模型驱动的场景编排

端到端文本到视频扩散模型的一个致命缺陷在于，它们无法在场景转换和长镜头中维持语义一致性、实体身份识别以及严格的物理布局控制²⁰。当被要求生成多场景叙事视频时，标准的生成模型会患上严重的“失忆症”：角色外貌发生突变、背景不合逻辑地扭曲、物理布局在镜头切换之间彻底消散²⁰。为了纠正这一系统性崩塌，研究人员正在探索不以刷分为导向的新范式，通过将LLM重新定位为“视频导演”或“场景调度员”，将高层认知推理与显式结构规划强行注入生成流水线中²。

VideoDirectorGPT架构是这一从端到端合成向多阶段智能体编排转变的典型代表²⁰。在该框架中，视频生成过程被进行了物理意义上的解耦。在核心的初始阶段，LLM（如GPT-4）作为全局视频规划师运作²⁰。LLM并非直接与像素生成器交互，而是将用户输入的单一文本提示词扩展为高度结构化、机器可读的“视频计划”（Video Plan）²⁰。这一总体情节大纲包含了场景级的文本描述、详尽的实体与背景元素清单、由空间边界框定义的逐帧实体物理布局，以及最关键的——显式地将不同场景中的实体身份在数学层面绑定在一起的一致性分组矩阵²⁰。在次级阶段，一个名为Layout2Vid的接地（Grounded）视频生成模块处理这些显式的空间布局和时间相干性指令以渲染

最终视频²⁰。通过将语义推理、时序逻辑和空间规划的重担完全卸载给LLM, 下游的扩散模块被限制为仅执行纯粹的渲染功能, 从而在不需要对视觉基础模型进行任何重度重新训练的情况下, 有效地消除了实体幻觉和跨场景不一致性²¹。

这种智能体规划范式正被积极扩展到细粒度的以人为中心的视频合成中。DirectorLLM框架将LLM从通用的场景规划师转变为高度专业化的人体运动模拟器²⁶。由于人体存在极其复杂的运动学约束, 生成真实自然的人体关节运动对于无引导的扩散模型来说是一项艰巨的任务¹²。DirectorLLM利用经过微调的Llama 3架构, 在任何视觉渲染发生之前, 显式地预测主体在三维空间中的位置、时间运动向量以及复杂的骨骼姿态, 并将其输出为离散词元¹²。该架构集成了一个向量量化变分自编码器(VQ-VAE), 将连续的人体姿态离散化为LLM可以通过自回归方式预测的词汇表¹²。这些生成的姿态词元随后由一个线性扩散模块处理, 该模块将稀疏的骨骼关键帧插值转化为密集、平滑的运动学序列¹²。最终, 这些显式的骨骼结构通过ControlNet机制引导最终的视频U-Net渲染, 确保了从文本到视频的转化过程中具备极高的解剖学保真度与时间连贯度¹²。

与此逻辑同源, Mora框架探索了多智能体协作网络, 利用现有的开源组件网络复刻甚至超越Sora等闭源高级模型的全面功能²⁸。通过部署自调节的多智能体系统, Mora在一个总体LLM逻辑控制器的统一调度下, 协调了功能独立的文本到图像(T2I)、图像到图像(I2I)、图像到视频(I2V)以及视频到视频(V2V)智能体²⁹。这种模块化的编排深刻揭示了一个新兴的范式转移: 视频生成的未来不在于盲目扩大单一黑盒模型的参数量, 而在于通过显式的语言逻辑规划, 对功能高度专业化、程序化的智能体网络进行协同路由与任务分发²⁹。

可执行事件图与确定性3D引擎的前沿融合

尽管基于LLM布局引导的方法极大地提高了一致性, 但它们在本质上仍然依赖于神经渲染引擎来合成最终的像素网络。这意味着它们依然处于概率生成的范畴, 输出的画面在本质上缺乏真正的物理验证机制和语义绝对保证³¹。为了彻底消除生成式幻觉, 并获得完美无瑕的时空真值注释, 一个极具颠覆性的子领域正在兴起: 完全绕过基于扩散的神经像素生成环节, 转而将自然语言直接翻译为驱动确定性3D模拟引擎的可执行代码或图结构³¹。

这种方法论通过生成时空事件图(Graph of Events in Space and Time, GEST)被严格形式化³¹。

GEST是一个具有严格定义的有向图, 在数学上表述为 $G = (V, E)$ 。其中, 节点(V)代表高度具体的原子级事件, 封装了诸如具体动作、参与的物理实体、空间位置、发生时间框架以及相关状态属性等数据³¹。边缘(E)则对事件之间复杂的逻辑网络进行编码, 包括时间约束(采用修改版的Allen时间区间代数)、拓扑空间关系以及将事件绑定在一起的因果语义依赖³³。

在利用GEST的智能体视频生成流水线中, 系统架构被拆分为一种极具层次结构的多智能体网络³²。最高层的“导演智能体”(Director Agent)负责在预定义的3D模拟世界中探索, 制定宏大的故事叙事结构并定义演员的底层原型³⁵。“导演”随后将具体的场景任务按顺序委托给“场景构建子智能体”(Scene Builder Subagent), 后者负责将自然语言编写的任务描述严格转化为离散的图节点操作³⁵。至关重要的是, 这些LLM智能体绝对不被允许直接修改GEST; 它们的所有输出必须严格通过一个专门的工具接口进行中介。该工具层会根据3D游戏引擎(例如基于Multi Theft Auto的GTA San Andreas引擎, 或Blender物理引擎)的能力注册表(包含可用的动作链、物理碰撞体积、对象

类型等),对每一个操作进行严苛的合法性验证³¹。如果LLM提议了一个违反引擎物理定律(如穿模)或拓扑约束的动作,工具层将直接拒绝该操作,迫使LLM进行递归反思并修正其逻辑闭环³¹。

这种工具约束下的LLM规划从结构上保证了生成的GEST在构造上是100%可执行的³²。当这个完备的GEST最终被3D引擎解析时,系统将以极其精确的确定性渲染出多角色的叙事视频。更具学术价值的是,这种机制同时以“零边际成本”自动生成了完美的真值注释(Ground-truth Annotations)³¹。这些伴随生成的注释包括像素级精确的RGB数据、帧同步的时间动作分割段、动态的空间关系图、多视角深度图以及完美贴合实例的分割掩码³¹。通过将视频生成从基于扩散的概率渲染任务转变为基于引擎的形式化规范任务,该范式为后续视觉模型的训练提供了一个前所未有的纯净数据平台,提供了神经生成器从根本上无法自我产生的逻辑自洽且多模态对齐的绝佳数据源³¹。

相关框架GPT4Motion践行了高度相似的哲学,它通过将GPT-4直接与Blender物理模拟引擎对接来实现物理绝对对齐²。GPT4Motion没有依赖扩散模型内部那套充满缺陷的流体动力学或刚体碰撞“视觉记忆”,而是指派LLM编写可执行的Python脚本。这些脚本直接在Blender内部实例化3D网格对象,应用重力、摩擦力,并模拟真实的物理交互²。这些物理上绝对准确的渲染结果随后被提取为深度图、法线图或边缘序列,进而作为条件输入给由ControlNet驱动的扩散模型²。这种模式显式地将保证物理一致性的重担卸载给专用的确定性计算引擎,实现了刚性物理定律与柔性概率渲染美学之间的无缝对接²。

物理接地机制的深入审视与幻觉的系统性消除

将3D引擎引入生成流程,暴露出标准视频生成模型中一个极为致命的漏洞:它们在进行细粒度物理推理时表现出了令人震惊的无能。尽管现代Video-LLM和视频扩散模型有能力生成令人惊叹的超写实纹理和光影效果,但它们在模拟最基础的物理定律(如重力加速度、物体恒存性、动量守恒和基础流体力学)时,却存在着无法掩盖的系统性缺陷⁶。

最近的理论研究将这一根本性缺陷正式命名为“语义先验主导”(Semantic Prior Dominance)现象⁸。统一归因理论指出,当生成模型面临反直觉的物理场景——即屏幕上显式的视觉事实与统计上的语言学期望相矛盾时,它们的推理机制会直接被其在文本预训练期间学习到的内在叙事脚本所劫持⁸。因此,模型会不可避免地生成物理上不可能的结果,仅仅是因为这些反常结果在庞大的文本语料库中具有更高的出现概率⁸。例如,当像素级别上存在关于球的尺寸相对于缝隙大小的视觉歧义时,扩散模型会放弃对空间几何的严谨计算,转而依赖启发式的视觉捷径,生成一个视觉上似乎合理但物理上绝对穿模的错误画面³⁸。这种基于语言概率压倒视觉几何规律的现象,是导致现代视频模型产生“物理幻觉”的核心病理机制。

为了系统性地评估并彻底暴露这些漏洞,研究界摒弃了传统的唯画质论,开发了以物理规则为核心的新型基准测试套件,例如VideoHallu⁹。VideoHallu从根本上超越了审美评估,它基于一个由专家精心标注、包含超过3000个合成视频的庞大语料库,并配对了大量反直觉、需要深度推理的问答集⁹。该基准测试专门精准打击四个核心维度的脆弱性:一是显式的物理定律违背(如反重力悬浮或不合逻辑的事件发展顺序);二是常识推理的系统性崩溃;三是时空一致性的丧失(如在多帧中无法稳定追踪实体运动);四是基础的视觉-文本感知对齐错误⁹。利用VideoHallu进行的大规模评估表明,即便是目前最前沿的多模态大模型,也经常无法检测到合成视频中明显的物理畸变

，这确凿地证明了模型将生成的伪影(Artifacts)与真正的物理谬误在概念上发生了深度的混淆⁸。缓解这些顽固的故障需要进行专门的侵入式干预，例如引入程序化对抗课程(PACC)，该方法利用强化学习微调，强制模型在进行任何高级逻辑裁决之前，必须将其判断严格锚定在低级视觉事实与几何约束之上⁸。

为了在不依赖外部3D引擎的情况下，将物理合理性直接原生地嵌入生成管线中，研究人员提出了诸如VLIPP(视觉与语言通知的物理先验)等创新模型⁶。VLIPP采用了一种双阶段图生视频(Image-to-Video)生成框架，显式地强制执行物理合规性。在粗粒度运动规划的初级阶段，模型部署一个视觉语言模型(VLM)利用思维链(CoT)提示技术和显式的物理感知推理，在二维图像空间中预测出粗略的物体运动轨迹⁶。在任何像素合成发生之前，这一步就建立起了帧间的一致性并锁定了基础的物理约束方向⁶。在精细级运动合成的次级阶段，这些预测出的运动轨迹被有意注入结构化噪声，作为引导后续视频扩散模型的光流条件⁶。噪声的引入是一项极具巧思的设计，它赋予了扩散模型在生成微小振动、真实的加速度以及流体边缘细节时充分的生成自由度，同时又保证模型如同被一根隐形的线牵引着一般，严格受限于VLM预先设定的、符合物理规律的宏观轨迹之上⁶。

在另一条技术路径上，PhyT2V框架通过LLM引导的迭代自我优化(Iterative Self-Refinement)机制，实现了基于物理规律的视频生成⁴²。PhyT2V引入了一种双轨推理机制：不仅利用局部思维链推理来识别并解决特定的物理子问题，还结合全局的后退式(Step-back)推理来评估总体提示词的改进效果。通过这种方式，PhyT2V能够在运行时动态地修改与打磨输入文本提示，从而强制基础扩散模型遵从现实世界的物理规律，整个过程完全独立于外部数据或渲染器的约束⁴²。

方法论架构	核心作用机制	解决的针对性问题	系统集成类型
GPT4Motion	将LLM提示深度转换为可执行的Blender Python脚本。	在任何渲染前显式模拟碰撞、重力加速度与流体动力学。	依赖外部独立3D物理引擎。
VLIPP	利用VLM中的CoT推理映射宏观轨迹线；随后利用结构化噪声引导扩散。	动量传递、物体碰撞反弹、多帧空间绝对一致性。	内部神经管线，基于光流场控制。
PhyT2V	文本提示的迭代自反思；局部/全局CoT双轨推理审查。	纠正生成模型对广泛物理定律的违背。	提示工程强化 / 自主纠错回环。

VideoHallu	构建反直觉合成视频问答对抗基准测试。	揭露语义先验主导现象；量化物理与常识幻觉。	离线评估基准 / RLHF强化微调框架。
------------	--------------------	-----------------------	----------------------

人机交互的演进与交互式视频智能体的崛起

超越单纯的结构优化与物理校准，当前视频研究的另一个宏大向量是将视频生成从一种被动接受的、黑盒化的批处理管线，转变为嵌入在人机交互(HCI)框架内的动态交互式智能体系统。这一范式极端强调“智能体工作流”(Agentic Workflows)，在其中，LLM扮演着持久且具有主动性的辅助角色，能够根据实时的人类反馈以及启发式的内部不确定性评估，不断地对视频理解与生成过程进行迭代⁴。

VideoAgent2架构完美展示了这种方法在长视频理解和编辑环境中的前沿应用。研究者敏锐地认识到，当LLM被要求从海量视觉帧中检索信息或编辑视频时，极易受到外部检索工具引入的噪声干扰而产生严重幻觉⁴⁴。为此，VideoAgent2创新性地引入了一种在“计划-调整模式”(Plan-adjust Mode)下运行的不确定性感知(Uncertainty-aware)思维链机制⁴⁴。在执行长视频任务时，LLM首先会启发式地评估其调用的每一个工具的不确定度⁴⁴。如果返回的数据表现出高不确定性或被判定含有噪声，智能体会立刻中止当前路径，主动调整其信息收集策略，重新规划新的工具调用序列，在合成最终答案或输出前进行深度的自我修正⁴⁴。这种具有强自我反思能力的图编排逻辑，使得智能体能够以极高的效率精准锁定关键帧，通过显式的逐步验证步骤，大幅消除了因外部工具缺陷而导致的幻觉⁴⁴。

这种强调交互与自适应的哲学正在直接重塑终端用户应用生态。重构任意视频智能体(Reframe Any Video Agent, RAVA)便是一个专门为自动化处理高度复杂的开放世界视频重构任务而设计的LLM智能体——它能够动态地将宽屏影视内容完美自适应裁剪为适合移动设备的垂直格式⁴⁷。RAVA的运行机制构建在一个包含感知、规划和执行三个阶段的持续反馈回路之上⁴⁷。在感知阶段，LLM不仅解析上下文相关的用户指令，还调用先进的分割工具识别出显著对象，构建出层次化的语义场景图⁴⁸。进入规划阶段后，智能体动态计算最佳长宽比，建立一个反映对象重要性层次的树状结构以决定画面的跟踪优先级，并基于叙事连贯性配置视觉布局⁴⁷。最后，它通过API调用严丝合缝地执行重构蓝图⁴⁷。与传统的、具有硬编码逻辑的程序化裁剪工具截然不同，RAVA核心的LLM使其能够深度理解极其微妙的自然语言人类指令，甚至能够根据人类主观的审美偏好要求动态调整其跟踪与裁切行为，实现了真正意义上的智能互动⁴⁸。

更具社会价值的是，交互式视频智能体正在打破关键的无障碍认知壁垒。ADCanvas系统代表了盲人和低视力(BLV)视频创作者在人机交互领域的一次重大飞跃⁴。传统的视频编辑软件和音频描述(AD)生成工具严重依赖于视觉GUI界面，这在物理和认知层面上将BLV创作者排斥在外⁵²。ADCanvas突破性地多模态LLM智能体直接集成到对屏幕阅读器极度友好的纯文本界面中，通过流畅的对话式交互，支持实时的视频视觉问答(VQA)、自动化的脚本生成以及音频描述的迭代修改⁴。在这种新颖的人机协作模式下，BLV用户将智能体视为辅助起草者和视觉信息提取器，利用对话查询深挖画面背后的视觉上下文⁴。同时，用户牢牢掌控着最终的创意主导权——他们充当

着“策展人”的角色，对AI的描述输出进行严格的过滤、验证与润色，最终生成面向盲人观众的音频轨道⁴。这有力地证明了，LLM正在从一种孤立的、被动的像素生成器，蜕变为极具协作精神的创意伙伴。通过高度可配置的多模态交互规则，LLM极大地增强了人类创作者，尤其是弱势群体对多媒体环境的掌控能力⁴。

参数化感知指标的落幕：JEPA嵌入距离(JEDi)的引入

随着视频模型生成能力与认知能力的爆炸式增长，学术界用来评估它们的传统指标已经暴露出致命的滞后性甚至方向性错误。多年来，弗雷歇视频距离(FVD)一直被奉为衡量生成视频时间连贯性和整体视觉质量的“黄金准则”⁵⁴。然而，近期的系统性统计学剖析彻底暴露了FVD公式中存在的严重数学缺陷与表征扭曲，这直接促使了完全不同的、非参数化的评估方法论的诞生⁵⁵。

FVD最根本的灾难性失败在于其对高斯假设(Gaussianity Assumption)的盲目依赖⁵⁵。为了能够计算弗雷歇距离，该指标强制假设真实视频和生成视频的高维特征分布都服从多元高斯分布⁵⁵。然而，广泛而严谨的统计测试(包括Mardia偏度测试和Henze-Zirkler正态性测试)已经确凿地证明，FVD所使用的底层特征空间表现出极度强烈的非高斯特性⁵⁵。因此，将高斯假设强加于非高斯数据之上，会得出在数学上站不住脚且极其不准确的分布距离估计值⁵⁵。

更为严重的是，FVD采用从Inflated 3D ConvNet(I3D)提取的特征嵌入，这是一种最初专门为Kinetics数据集上的动作分类任务而优化的陈旧架构⁵⁵。研究无情地揭示了I3D特征表现出深度的“内容偏见”(Content-bias)；它们在评估时严重向静态的、逐帧的图像空间质量倾斜，而极大程度上忽视了视频最核心的属性——流畅的时间一致性⁵⁵。虽然I3D特征对诸如JPEG压缩等基础图像失真高度敏感，但它们对生成模型中常见的致命故障，如运动崩溃(Motion Collapse)、高频时间闪烁以及反物理规律的帧突变，表现出令人震惊的迟钝⁵⁵。此外，FVD的样本效率极低，通常需要吞吐数千个生成视频才能计算出一个统计上稳定的协方差矩阵，这使得其在资源受限环境下的快速迭代测试变得完全不可行⁵⁵。

为了彻底清算这些架构性缺陷，研究人员提出了JEDi(JEPA Embedding Distance)作为全新的评估范式⁵⁵。JEDi果断抛弃了充满缺陷的I3D主干，转而利用从视频联合嵌入预测架构(V-JEPA)中提取的特征⁵⁵。V-JEPA是一种在高度抽象的表征空间中，通过预测视频中被掩码的时空区域来进行自我监督训练的前沿模型⁵⁵。这种训练范式强制其嵌入空间原生且深度地对空间关系和极其平滑的时间动态进行联合编码，从而大幅度提高了其对运动崩溃和时间闪烁的感知敏感度⁵⁵。

在数学机制上，JEDi彻底摒弃了引发争议的参数化高斯假设。JEDi不再计算弗雷歇距离，而是采用通过多项式核(Polynomial Kernel)映射的最大均值差异(Maximum Mean Discrepancy, MMD)⁵⁵。这种非参数化的优雅方法直接在再生核希尔伯特空间中比较真实分布与生成分布的平均嵌入之间的距离⁵⁶。从弗雷歇距离到MMD多项式核的数学转变带来了性能的飞跃。JEDi达到稳定收敛值所需的样本量仅仅是FVD所需样本量的16%，这使得研究人员能够在规模极小的数据集上进行极其稳健的评估⁵⁵。更有力的实证研究证明，无论评估的视频片段被拉长到何种程度，JEDi距离都能保持完美的稳定性；相反，FVD分数则会荒谬地随着视频时长的增加而人为膨胀⁵⁵。最终，通过MMD评估的V-JEPA特征表征在与真实人类感官判断的对齐度上，比FVD大幅提升了34%，由此，JEDi为视频质量评估确立了一个无可争议、数学严谨的新标杆⁵⁵。

伦理对齐与部署后的去偏置架构

随着文本到视频模型在社会与商业领域的部署日益深入，其生成输出的伦理影响已经从纯粹的理论争论转变为亟待解决的硬核工程挑战。在互联网规模的、未经严格筛选的数据集上训练出来的生成式基础模型，不可避免地会吸收、固化，并在很多情况下极端放大社会中预先存在的关于性别、种族、年龄以及职业刻板印象的偏见⁵⁸。传统的去偏置手段通常涉及大规模的数据过滤和计算成本极其高昂的模型重训练(Retraining)。然而，对于动辄拥有数百亿参数的视频基础大模型而言，这种重训练在算力成本和迭代周期上往往是完全不切实际的⁶²。

因此，视频生成领域涌现出一个极具挑战性的新子任务：如何在部署后阶段(Post-deployment Phase)，在不改变基础模型架构、不需要任何重新训练的情况下，有效地减轻偏见并确保生成的公平性。诸如Fair Diffusion等方法论代表了该领域的重大工程突破⁶²。Fair Diffusion创新性地引入了一种控制机制，允许操作员完全基于显式的人类文本指令来衰减生成偏见⁶²。通过在推理(Inference)阶段精确地操控并修改语义引导向量(Semantic Guidance Vectors)，该框架可以动态地改变生成属性(例如，身份群体、特定职业环境下的性别比例)的分布。这种向量空间的微操可以将属性分布向任何指定的方向推移，从而产生符合人类意图、具有任意定义比例的特征表征⁶²。

这一方法论最卓越之处在于，它完全独立于模型原始的训练语料库运行⁶²。它使得学术研究者 and 商业平台提供商能够在运行时(Runtime)即时向生成式扩散模型注入公平性指令，确保所合成的视频内容严格符合当代的道德伦理标准和包容性要求，而绝不牺牲或降低模型底层的生成保真度与美学质量⁶²。并行的研究路径，例如ITI-GEN框架，则利用基于视觉参考的技术来实现包容性生成。该框架的研究者指出，直接注入代表多样性属性的视觉参考嵌入(Visual References)，比单纯依赖容易产生歧义的文本提示词工程(Prompt Engineering)能提供更稳定、更精确的去偏置效果⁶⁴。随着围绕AI透明度和公平性的国际监管框架日趋成熟，这些部署后的语义操作与隐空间干预技术必将成为视频生成系统中不可或缺的底层基础设施，它们对于确保多模态资源的公平分配，以及防止在合成媒体中固化和传播有害的社会文化刻板印象具有不可估量的价值⁶⁰。

结语

综上所述，视频生成领域正在经历一场极其深刻的底层重构。研究界正以决绝的姿态，从对孤立感知指标(如FVD)的无限榨取中抽身，转向致力于攻克长久以来被忽视的结构性、认知性与物理性瓶颈。从离散的回归分词向连续向量表征(如CALM与TokenBridge)的跨越，正在打破长期束缚多模态合成的算力效率枷锁。与此同时，“无限视频理解”这一蓝天目标的提出，正在引发内存架构的彻底革命，推动视频处理范式从有限上下文的批处理模式跃迁至连续、流式的深层语义解析。

在这一进程中，大语言模型(LLMs)的角色发生了翻天覆地的变化。以VideoDirectorGPT和DirectorLLM为代表的架构证明，将空间布局约束、跨场景时间一致性计算以及复杂的人体运动学规划委托给一个作为全局调度者的认知规划引擎，能够从根本上治愈无引导扩散模型中普遍存在的“失忆症”与语义幻觉。进一步地，将具有严格数学定义的形式化结构(如时空事件图GEST)以及独立的3D物理引擎与LLM的脚本生成能力相融合，为彻底根除物理幻觉提供了终极方案，它强行将概率主导的像素生成锚定在了确定性的物理定律之上。

随着VideoHallu等反直觉基准测试的普及以及VLIPP等物理先验模型的落地，物理逻辑的合理性已成为衡量模型优劣的核心标尺。与模型交互的范式同样在快速成熟：在长视频分析中引入不确定性感知推理链，以及为视障创作者开发会话式无障碍交互接口，生动展现了LLM作为实时、主动的创造性智能体的巨大潜力。为了精准刻画这一系列深刻的变革，非参数化的JEDi距离等新型评估准则正在迅速取代充满结构性缺陷的旧日标准，使得计算评估与真实的人类认知逻辑重新对齐。最终，智能体驱动、物理接地、连续表征与伦理对齐这四大新范式的深度融合，清晰地描绘了视频生成领域未来的演进图景：我们将不再满足于生成一段精美的动画，而是致力于构建一个在数学上严谨、在物理上自洽，且具备无限扩展能力的多模态世界模拟器。

引用的著作

1. Evolution of Video Generative Foundations - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2604.06339v1>
2. Generative AI for Text-to-Video Generation: Recent Advances and Future Directions - MDPI, 访问时间为 五月 8, 2026, <https://www.mdpi.com/2673-6470/6/1/23>
3. A Survey on Long-Video Storytelling Generation: Architectures, Consistency, and Cinematic Quality - CVF Open Access, 访问时间为 五月 8, 2026, https://openaccess.thecvf.com/content/ICCV2025W/LongVid-Foundation/papers/Elmoghany_A_Survey_on_Long-Video_Storytelling_Generation_Architectures_Consistency_and_Cinematic_ICCVW_2025_paper.pdf
4. Human-Computer Interaction and Visualization - Google Research, 访问时间为 五月 8, 2026, <https://research.google/research-areas/human-computer-interaction-and-visualization/>
5. Infinite Video Understanding - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2507.09068v2>
6. VLIPP: Towards Physically Plausible Video ... - CVF Open Access, 访问时间为 五月 8, 2026, https://openaccess.thecvf.com/content/ICCV2025/papers/Yang_VLIPP_Towards_Physically_Plausible_Video_Generation_with_Vision_and_Language_ICCV_2025_paper.pdf
7. NeurIPS Poster Learning World Models for Interactive Video Generation, 访问时间为 五月 8, 2026, <https://neurips.cc/virtual/2025/poster/118999>
8. From Priors to Perception: Grounding Video-LLMs in Physical Reality - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2605.04515v1>
9. VideoHallu: Evaluating and Mitigating Multi-modal Hallucinations for Synthetic Videos, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2505.01481v1>
10. GPT4Motion: Scripting Physical Motions in Text-to-Video Generation via Blender-Oriented GPT Planning - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2311.12631v3>
11. Bridging Continuous and Discrete Tokens for Autoregressive Visual Generation - CVF Open Access, 访问时间为 五月 8, 2026, https://openaccess.thecvf.com/content/ICCV2025/papers/Wang_Bridging_Continuous_and_Discrete_Tokens_for_Autoregressive_Visual_Generation_ICCV_2025_p

- [aper.pdf](#)
12. DirectorLLM for Human-Centric Video Generation - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2412.14484v1>
 13. Continuous Autoregressive Language Models - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2510.27688v1>
 14. Video Generation Models Explosion 2024 - Yen-Chen Lin, 访问时间为 五月 8, 2026, <https://yenchelin.me/blog/2025/01/08/video-generation-models-explosion-2024/>
 15. Infinite Video Understanding | Request PDF - ResearchGate, 访问时间为 五月 8, 2026, https://www.researchgate.net/publication/393684999_Infinite_Video_Understanding
 16. Infinite Video Understanding - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/pdf/2507.09068>
 17. StreamingVLM: Real-Time Understanding for Infinite Video Streams | OpenReview, 访问时间为 五月 8, 2026, <https://openreview.net/forum?id=gVbPWbA97s>
 18. yunlong10/Awesome-LLMs-for-Video-Understanding: [IEEE TCSVT] Latest Papers, Codes and Datasets on Vid-LLMs. - GitHub, 访问时间为 五月 8, 2026, <https://github.com/yunlong10/awesome-llms-for-video-understanding>
 19. Infinite Video Understanding - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2507.09068v1>
 20. official implementation of VideoDirectorGPT: Consistent Multi-scene Video Generation via LLM-Guided Planning (COLM 2024) - GitHub, 访问时间为 五月 8, 2026, <https://github.com/HL-hanlin/VideoDirectorGPT>
 21. VideoDirectorGPT: Consistent Multi-Scene Video Generation via LLM-Guided Planning, 访问时间为 五月 8, 2026, https://j-min.io/publication/videodirectorgpt_colm2024/
 22. VideoDirectorGPT: Consistent Multi-Scene Video Generation via LLM-Guided Planning, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2309.15091v2>
 23. TalkCuts: A Large-Scale Dataset for Multi-Shot Human Speech Video Generation, 访问时间为 五月 8, 2026, <https://neurips.cc/virtual/2025/poster/121841>
 24. [2309.15091] VideoDirectorGPT: Consistent Multi-scene Video Generation via LLM-Guided Planning - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/abs/2309.15091>
 25. VideoDirectorGPT: Consistent Multi-Scene Video Generation via LLM-Guided Planning, 访问时间为 五月 8, 2026, <https://openreview.net/forum?id=sKNljS2brr>
 26. Daily Papers - Hugging Face, 访问时间为 五月 8, 2026, <https://huggingface.co/papers?q=action-centered%20video%20generation%20model>
 27. Llama Learns to Direct: DirectorLLM for Human-Centric Video Generation - BMVA Archive, 访问时间为 五月 8, 2026, https://bmva-archive.org.uk/bmvc/2025/assets/papers/Paper_896/poster.pdf
 28. Mora: Enabling Generalist Video Generation via A Multi-Agent Framework -

- OpenReview, 访问时间为 五月 8, 2026,
<https://openreview.net/forum?id=S7F7IMGX4O>
29. Mora: Enabling Generalist Video Generation via A Multi-Agent Framework - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2403.13248v3>
 30. Mora: Enabling Generalist Video Generation via A Multi-Agent Framework - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2403.13248v1>
 31. Agentic Video Generation: From Text to Executable Event Graphs via Tool-Constrained LLM Planning - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2604.10383v1>
 32. [2604.10383] Agentic Video Generation: From Text to Executable Event Graphs via Tool-Constrained LLM Planning - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/abs/2604.10383>
 33. arXiv:2305.12940v1 [cs.CL] 22 May 2023, 访问时间为 五月 8, 2026, <https://arxiv.org/pdf/2305.12940>
 34. GEST: the Graph of Events in Space and Time as a Common Representation between Vision and Language - ResearchGate, 访问时间为 五月 8, 2026, https://www.researchgate.net/publication/370949340_GEST_the_Graph_of_Events_in_Space_and_Time_as_a_Common_Representation_between_Vision_and_Language
 35. Agentic Video Generation: From Text to Executable Event Graphs via Tool-Constrained LLM Planning - ResearchGate, 访问时间为 五月 8, 2026, https://www.researchgate.net/publication/403790658_Agentic_Video_Generation_From_Text_to_Executable_Event_Graphs_via_Tool-Constrained_LLM_Planning
 36. [tiny paper] gest-engine: controllable multi-actor video synthesis with perfect spatiotemporal annotations - OpenReview, 访问时间为 五月 8, 2026, <https://openreview.net/attachment?id=uUofPYVMZH&name=pdf>
 37. GPT4Motion: Scripting Physical Motions in Text-to-Video Generation via Blender-Oriented GPT Planning, 访问时间为 五月 8, 2026, https://openaccess.thecvf.com/content/CVPR2024W/PBDL/papers/Lv_GPT4Motion_Scripting_Physical_Motions_in_Text-to-Video_Generation_via_Blender-Oriented_GPT_CVPRW_2024_paper.pdf
 38. How Far is Video Generation from World Model: A Physical Law Perspective, 访问时间为 五月 8, 2026, <https://phyworld.github.io/>
 39. VideoHallu: Evaluating and Mitigating Multi-modal Hallucinations on Synthetic Video Understanding - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2505.01481v4>
 40. VideoHallu: Evaluating and Mitigating Multi-modal Hallucinations on Synthetic Video Understanding | OpenReview, 访问时间为 五月 8, 2026, <https://openreview.net/forum?id=NoC9HT7Kf7>
 41. VideoHallu: Evaluating and Mitigating Multi-modal Hallucinations on Synthetic Video Understanding - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2505.01481v2>
 42. PhyT2V: LLM-Guided Iterative Self-Refinement for Physics-Grounded Text-to-Video Generation - IEEE Xplore, 访问时间为 五月 8, 2026, <https://ieeexplore.ieee.org/iel8/11091818/11091608/11092954.pdf>

43. official code repo of CVPR 2025 paper PhyT2V: LLM-Guided Iterative Self-Refinement for Physics-Grounded Text-to-Video Generation - GitHub, 访问时间为 五月 8, 2026, <https://github.com/pittisl/PhyT2V>
44. VideoAgent2: Enhancing the LLM-Based Agent System for Long-Form Video Understanding by Uncertainty-Aware CoT - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2504.04471v1>
45. VideoAgent2: Enhancing the LLM-Based Agent System for Long-Form Video Understanding by Uncertainty-Aware CoT - Semantic Scholar, 访问时间为 五月 8, 2026, <https://www.semanticscholar.org/paper/VideoAgent2%3A-Enhancing-the-LLM-Based-Agent-System-Zhi-Wu/91dbe991f2b3655902544d5414d8cc0e87bc9c06>
46. VideoAgent2: Enhancing the LLM-Based Agent System for Long-Form Video Understanding by Uncertainty-Aware CoT - OpenReview, 访问时间为 五月 8, 2026, <https://openreview.net/pdf?id=MD8QylZIoE>
47. LLM Agent for Open World Video Reframing - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2403.06070v1>
48. [Literature Review] Reframe Anything: LLM Agent for Open World Video Reframing, 访问时间为 五月 8, 2026, <https://www.themoonlight.io/en/review/reframe-anything-llm-agent-for-open-world-video-reframing>
49. Reframe Anything: LLM Agent for Open World Video Reframing - NextVid Workshop@NeurIPS 2025, 访问时间为 五月 8, 2026, https://what-makes-good-video.github.io/assets/27_Reframe_Anything_LLM_Agent.pdf
50. [2602.07266] ADCanvas: Accessible and Conversational Audio Description Authoring for Blind and Low Vision Creators - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/abs/2602.07266>
51. Research - Michael Xieyang Liu, 访问时间为 五月 8, 2026, <https://lxieyang.github.io/research/>
52. Cynthia Bennett - Google Research, 访问时间为 五月 8, 2026, <https://research.google/people/108223/>
53. Describe Now: User-Driven Audio Description for Blind and Low Vision Individuals | Request PDF - ResearchGate, 访问时间为 五月 8, 2026, https://www.researchgate.net/publication/393430364_Describe_Now_User-Driven_Audio_Description_for_Blind_and_Low_Vision_Individuals
54. Essential AI Video Generation Benchmarking Metrics Guide - Troy Lendman, 访问时间为 五月 8, 2026, <https://troylendman.com/essential-ai-video-generation-benchmarking-metrics-guide/>
55. BEYOND FVD: AN ENHANCED METRIC FOR EVALUATING ..., 访问时间为 五月 8, 2026, https://proceedings.iclr.cc/paper_files/paper/2025/file/a57483b394a3654f4317051e4ce3b2b8-Paper-Conference.pdf
56. Beyond FVD: An Enhanced Evaluation Metrics for Video Generation Distribution Quality | OpenReview, 访问时间为 五月 8, 2026,

- <https://openreview.net/forum?id=cC3LxGZasH>
57. [2410.05203] Beyond FVD: Enhanced Evaluation Metrics for Video Generation Quality - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/abs/2410.05203>
 58. Bias and Fairness in Large Language Models: A Survey - MIT Press Direct, 访问时间为 五月 8, 2026, <https://direct.mit.edu/coli/article/50/3/1097/121961/Bias-and-Fairness-in-Large-Language-Models-A>
 59. The Ethical Implications of Large Language Models in AI - IEEE Computer Society, 访问时间为 五月 8, 2026, <https://www.computer.org/publications/tech-news/trends/ethics-of-large-language-models-in-ai>
 60. Navigating the Ethical Terrain of AI-Generated Text Tools: A Review - IEEE Xplore, 访问时间为 五月 8, 2026, <https://ieeexplore.ieee.org/iel8/6287639/10380310/10813359.pdf>
 61. (PDF) ETHICAL IMPLICATIONS AND BIAS IN GENERATIVE AI - ResearchGate, 访问时间为 五月 8, 2026, https://www.researchgate.net/publication/384469530_ETHICAL_IMPLICATIONS_AND_BIAS_IN_GENERATIVE_AI
 62. Auditing and instructing text-to-image generation models on fairness ..., 访问时间为 五月 8, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12103484/>
 63. Gender Bias in Text-to-Video Generation Models: A Case Study of Sora, 访问时间为 五月 8, 2026, <https://www.computer.org/csdl/magazine/ex/2025/03/11031156/27sQJ8UUblI>
 64. FairT2I: Mitigating Social Bias in Text-to-Image Generation via Large Language Model-Assisted Detection and Attribute Rebalancing - arXiv, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2502.03826v1>
 65. Debiasing Text-to-Image Generation with Entanglement-Free Attention - CVF Open Access, 访问时间为 五月 8, 2026, https://openaccess.thecvf.com/content/ICCV2025/papers/Park_Fair_Generation_without_Unfair_Distortions_Debiasing_Text-to-Image_Generation_with_Entanglement-Free_ICCV_2025_paper.pdf
 66. A Survey on Generative AI and LLM for Video Generation, Understanding, and Streaming, 访问时间为 五月 8, 2026, <https://arxiv.org/html/2404.16038v1>